UNIVERSIDAD POLITÉCNICA DE ATLAUTLA

Ingeniería en Tecnologías de la Información e Innovación Digital

S1

Aplicaciones y casos de estudio de IA

Actividad Parcial 2 · Fundamentos de Inteligencia Artificial

Tema 1.7 · Salud, industria y movilidad

Alumno	Rogerio Aguilar Bello
Matrícula	24315118
Grupo / cuatrimestre	171 · 7.º
Docente	Mtro. Javier García Lara
Tipo de entrega	Individual · 50 pts
Fecha de entrega	18 de octubre de 2026
Referencias del tema	García Serrano (2016), cap. 1; Russell y Norvig (2020), cap. 1
Repositorio GitHub	[https://github.com/usuario/FIA-portafolio]

Capítulo 1. Planteamiento del problema

1.1 Contexto

La inteligencia artificial (IA) se aplica hoy en sectores muy distintos, pero la calidad de la evidencia sobre su impacto varía: muchas notas reportan resultados espectaculares sin fuente verificable ni método de medición. Para estudiar la IA con rigor, se requieren casos reales con problema definido, técnica identificable, indicador (KPI) cuantificable y fuente que cualquiera pueda consultar.

1.2 Problema

¿Cómo comprobar que una aplicación de IA resolvió un problema real con impacto medible y fuente verificable, y qué técnica de IA lo hizo posible?

1.3 Preguntas de investigación

- ¿Qué problema resolvió cada caso y en qué sector?
- ¿Qué rama y técnica de IA se emplearon?
- ¿Qué KPI demuestran el impacto y qué tan sólida es la evidencia?
- ¿Qué limitaciones técnicas y éticas se identifican?

1.4 Alcance

Se analizan tres casos documentados en salud, industria y movilidad. Dos provienen de artículos científicos o técnicos revisados por pares (Abràmoff et al., 2018; Holland et al., 2017) y uno de una publicación técnica oficial de la empresa (Evans y Gao, 2016).

Capítulo 2. Objetivos

2.1 Objetivo general

Analizar tres casos reales de aplicación de IA en salud, industria y movilidad **mediante** una matriz de criterios y fuentes verificables **para** identificar las técnicas empleadas, el impacto medible y las limitaciones de cada solución.

2.2 Objetivos específicos

- **Seleccionar** tres casos reales **aplicando** criterios explícitos de inclusión **para** trabajar solo con casos documentados y comparables.
- **Describir** el problema, la técnica de IA y el KPI de cada caso **extrayendo** los datos de fuentes primarias **para** respaldar cada cifra con una referencia.
- **Comparar** los casos por rama de IA, técnica, sector, KPI y país **mediante** una infografía y una tabla **para** reconocer patrones y diferencias.
- **Evaluar** la calidad de la evidencia y las limitaciones de cada caso **con** criterios técnicos y éticos **para** formular conclusiones reflexivas.

Capítulo 3. Fundamentos

Se adopta la visión de la IA como el diseño de agentes que perciben su entorno y actúan para lograr objetivos (Russell y Norvig, 2020, cap. 1); García Serrano (2016, cap. 1) ofrece el panorama de aplicaciones y ramas que organiza la comparación. Las ramas relevantes para los casos son:

- **Aprendizaje automático y aprendizaje profundo:** modelos que aprenden patrones a partir de datos (por ejemplo, imágenes o series de sensores).
- **Búsqueda y optimización heurística:** métodos que exploran un espacio de soluciones para hallar buenas soluciones sin recorrerlo completo; una *metaheurística* no garantiza el óptimo, pero entrega soluciones de alta calidad en tiempo útil.

KPI utilizados. *Sensibilidad*: proporción de casos enfermos que el sistema detecta. *Especificidad*: proporción de casos sanos que clasifica como sanos. *Imageabilidad*: proporción de pacientes con imágenes analizables. *PUE* (Power Usage Effectiveness): energía total de un centro de datos entre la energía de sus equipos de cómputo; mientras más cercano a 1, más eficiente.

Capítulo 4. Metodología y procedimiento

4.1 Criterios de selección

Un caso se incluyó si cumplió los cinco criterios siguientes:

Criterio	IDx-DR	Google/DeepMind	UPS ORION
C1. Problema real en operación o ensayo clínico	Sí (ensayo prospectivo)	Sí (centro de datos en operación)	Sí (55,000 rutas diarias)
C2. Técnica de IA identificable	Sí	Sí	Sí
C3. KPI cuantitativo	Sí	Sí	Sí
C4. Fuente verificable (DOI o URL oficial)	Sí (DOI)	Sí (URL oficial)	Sí (DOI)
C5. Sector distinto al de los otros casos	Salud	Industria	Movilidad

4.2 Procedimiento

- Definir los criterios C1 a C5 y la matriz de comparación (rama de IA, técnica, sector, KPI, país).
- Buscar en repositorios y sitios oficiales (PubMed Central, INFORMS PubsOnLine, sitio de DeepMind) y preseleccionar candidatos.
- Extraer problema, técnica y KPI directamente de la fuente primaria, registrando la cita.
- Verificar cada cifra contra la fuente primaria y, cuando existió, contra una segunda fuente.
- Ejecutar el script de Python (capítulo 7) para generar la matriz, la infografía y las verificaciones numéricas.
- Analizar la calidad de la evidencia, las limitaciones y redactar conclusiones.

Capítulo 5. Desarrollo: casos de estudio

5.1 Caso de salud: IDx-DR, diagnóstico autónomo de retinopatía diabética (EE. UU.)

Descripción	Sistema que analiza imágenes de la retina tomadas en consultorios de atención primaria y detecta retinopatía diabética mayor que leve y edema macular diabético sin que un médico interprete la imagen. Con base en este ensayo, la FDA lo autorizó en 2018 como el primer sistema diagnóstico autónomo de IA autorizado en cualquier campo de la medicina (Abràmoff et al., 2018).

Problema resuelto	Llevar diagnóstico de nivel especialista a la atención primaria para detectar a tiempo a las personas con diabetes que requieren evaluación por un especialista y prevenir pérdida de visión (Abràmoff et al., 2018).
Técnicas empleadas	Visión por computadora con aprendizaje profundo sobre imágenes de fondo de ojo. El personal del consultorio capturó las imágenes tras una capacitación estandarizada.
Impacto medible	Ensayo prospectivo con 900 personas con diabetes en 10 consultorios de atención primaria. Sensibilidad 87.2 % (IC 95 %: 81.8–91.2 %; meta > 85 %), especificidad 90.7 % (88.3–92.7 %; meta > 82.5 %) e imageabilidad 96.1 %. La referencia fue el grado del Wisconsin Fundus Photograph Reading Center.
Fuente verificable	Abràmoff et al. (2018), *npj Digital Medicine*, 1, 39. https://doi.org/10.1038/s41746-018-0040-6
Limitaciones	Requiere una cámara específica (Topcon NW400, ≈ 18,000 USD), solo clasifica retinopatía diabética (no otras enfermedades de la retina) y excluye a muchos pacientes con retinopatía previa (“With an eye to AI”, 2018).

5.2 Caso de industria: enfriamiento de centros de datos de Google con DeepMind (EE. UU. / Reino Unido)

Descripción	Google y DeepMind aplicaron aprendizaje automático a los centros de datos de Google para recomendar la operación del sistema de enfriamiento (bombas, enfriadores y torres de enfriamiento), uno de los principales consumos de energía de estas instalaciones (Evans y Gao, 2016).
Problema resuelto	Cada centro de datos tiene una arquitectura y un entorno únicos, con interacciones complejas entre equipos, por lo que las reglas de ingeniería generales dejan margen de ahorro sin aprovechar (Evans y Gao, 2016).
Técnicas empleadas	Aprendizaje automático supervisado con redes neuronales entrenadas con datos históricos de sensores para predecir el PUE y la temperatura de la instalación en la hora siguiente; esas predicciones se usan para no entregar más enfriamiento del necesario.
Impacto medible	En una prueba en un centro de datos en operación, el sistema logró de forma consistente una reducción de 40 % en la energía de enfriamiento, equivalente a 15 % menos de sobrecarga del PUE, y el PUE más bajo que el sitio había registrado (Evans y Gao, 2016).
Fuente verificable	Evans, R., y Gao, J. (2016, 20 de julio). *DeepMind AI reduces Google data centre cooling bill by 40%*. Google DeepMind. https://deepmind.google/discover/blog/deepmind-ai-reduces-google-data-centre-cooling-bill-by-40/
Limitaciones	Las cifras las reporta la propia empresa en una publicación técnica sin revisión por pares y provienen de una prueba en un sitio; la fuente habla de “hasta 40 %”, por lo que no debe generalizarse a cualquier centro de datos.

5.3 Caso de movilidad: UPS ORION, optimización de rutas de entrega (EE. UU.)

Descripción	ORION (On-Road Integrated Optimization and Navigation) entrega cada día una ruta optimizada a cada uno de los 55,000 conductores de UPS en EE. UU., según los paquetes por recoger y entregar ese día (Holland et al., 2017). Recibió el Premio Franz Edelman 2016 de INFORMS.
Problema resuelto	Ordenar las paradas de una ruta es un problema de optimización combinatoria de tipo agente viajero con restricciones de tiempo: el espacio de búsqueda crece factorialmente con el número de paradas, de modo que planear a mano o con reglas simples desperdicia millas y combustible.
Técnicas empleadas	Sistema de optimización basado en metaheurísticas (búsqueda heurística), alimentado con datos telemáticos y de direcciones, que además mantiene la consistencia de las rutas de un día a otro (Holland et al., 2017).
Impacto medible	Ahorro esperado de 300 a 400 millones de USD por año y 100,000 toneladas menos de CO_2 anuales (Holland et al., 2017); UPS reporta además 100 millones de millas y 10 millones de galones de combustible menos por año (“‘ORION’ delivers success”, 2016). El desarrollo y despliegue costó más de 295 millones de USD.
Fuente verificable	Holland, C., Levis, J., Nuggehalli, R., Santilli, B., y Winters, J. (2017). UPS optimizes delivery routes. *Interfaces*, 47(1), 8–23. https://doi.org/10.1287/inte.2016.0875
Limitaciones	Costo y tiempo de desarrollo elevados (cerca de 10 años); las primeras versiones del algoritmo no funcionaron bien en campo y fue necesaria una gestión del cambio con usuarios y directivos (Holland et al., 2017; “‘ORION’ delivers success”, 2016). Las cifras de ahorro son de la empresa, aunque se publicaron en una revista revisada por pares.

Capítulo 6. Resultados: infografía y tabla comparativa

6.1 Infografía comparativa

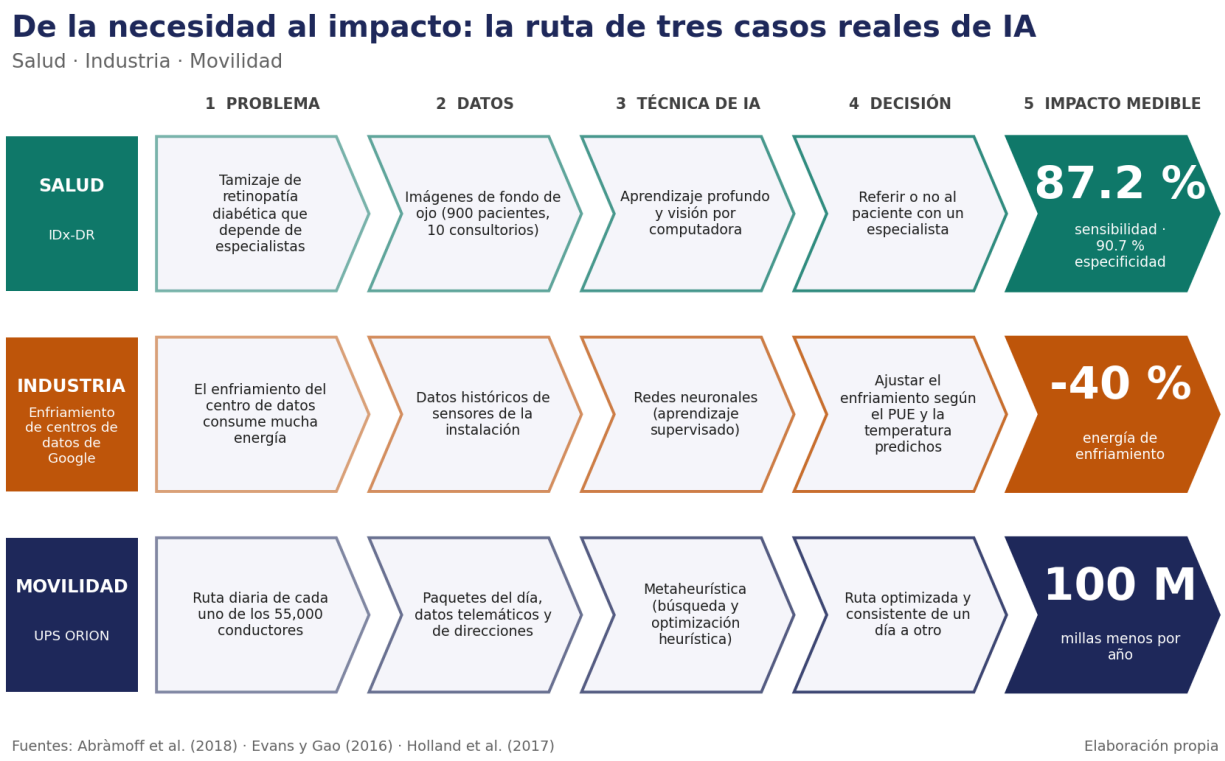


Figura 1. Ruta de cada caso, del problema al impacto medible, con la rama y técnica de IA de cada etapa. Elaboración propia con Python (matplotlib).

6.2 Tabla con criterios de comparación

Caso	Rama de IA	Técnica	Sector	KPI	País	Tipo de fuente
IDx-DR	Aprendizaje profundo / visión por computadora	Redes neuronales sobre imágenes de fondo de ojo	Salud	Sensibilidad 87.2 %; especificidad 90.7 %; imageabilidad 96.1 %	EE. UU.	Artículo revisado por pares (ensayo prospectivo)
Google / DeepMind	Aprendizaje automático supervisado	Redes neuronales que predicen PUE y temperatura	Industria	−40 % energía de enfriamiento; −15 % sobrecarga del PUE	EE. UU. / Reino Unido	Publicación técnica de la empresa
UPS ORION	Búsqueda y optimización heurística	Metaheurística + datos telemáticos	Movilidad / logística	100 M millas y 10 M galones menos por año; 300–400 M USD de ahorro anual	EE. UU.	Artículo revisado por pares (Interfaces)

6.3 Verificaciones numéricas (salida del script)

Salida real del script (cálculos de coherencia de las cifras publicadas):

```
IDx-DR PPV (prev. 10 %): 51.0%
IDx-DR NPV (prev. 10 %): 98.5%
ORION millas/conductor/día: 7.3
Google: ratio PUE/enfriamiento: 0.375
```

Interpretación. Con la sensibilidad y especificidad publicadas y una prevalencia *hipotética* de 10 %, cerca de la mitad de los resultados positivos serían falsos positivos (VPP ≈ 51 %), mientras que un resultado negativo es muy confiable (VPN ≈ 98.5 %): el sistema sirve para tamizar y referir, no para diagnosticar de forma definitiva. En ORION, 100 millones de millas entre 55,000 conductores y 250 días laborales (supuesto propio) equivalen a ≈ 7.3 millas por conductor al día, un ahorro diario modesto que, multiplicado por la escala de la flota, explica el impacto anual.

Capítulo 7. Código Python

Script completo y reproducible (`fia_s1_casos_ia.py`). Requisitos: `pip install pandas matplotlib`. Genera `matriz_casos_ia.csv` e `infografia_comparativa.png`. Se ejecutó con los datos de entrada del propio script y la salida está en la sección 6.3. Se usaron pandas (McKinney, 2010) y matplotlib (Hunter, 2007).

```
"""
FIA - Actividad Parcial 2 - Sección 1 (1.7 Aplicaciones y casos de estudio de IA)
Genera: (1) matriz comparativa en CSV, (2) métricas de verificación, (3) infografía PNG.

Requisitos: pip install pandas matplotlib
Uso:        python fia_s1_casos_ia.py
"""
import pandas as pd
import matplotlib
matplotlib.use("Agg")
import matplotlib.pyplot as plt
from matplotlib.patches import FancyBboxPatch

# ---------------------------------------------------------------------------
# 1. DATOS: cada caso con su fuente verificable (ver Referencias APA 7 en el PDF)
# ---------------------------------------------------------------------------
CASOS = [
    {
        "caso": "IDx-DR (diagnóstico autónomo)",
        "sector": "Salud",
        "pais": "EE. UU.",
        "rama_ia": "Aprendizaje profundo / visión por computadora",
        "tecnica": "Redes neuronales sobre imágenes de fondo de ojo",
        "kpi_principal": "Sensibilidad 87.2 % | Especificidad 90.7 %",
        "kpi_valor": "87.2 %",
        "kpi_etiqueta": "sensibilidad",
        "fuente": "Abràmoff et al. (2018)",
        "anio": 2018,
    },
    {
        "caso": "Enfriamiento de centros de datos de Google",
        "sector": "Industria",
        "pais": "EE. UU. / Reino Unido",
        "rama_ia": "Aprendizaje automático supervisado",
        "tecnica": "Redes neuronales que predicen PUE y temperatura",
        "kpi_principal": "-40 % energía de enfriamiento | -15 % sobrecarga PUE",
        "kpi_valor": "-40 %",
        "kpi_etiqueta": "energía de enfriamiento",
        "fuente": "Evans y Gao (2016)",
        "anio": 2016,
    },
    {
        "caso": "UPS ORION (ruteo de entregas)",
        "sector": "Movilidad / logística",
        "pais": "EE. UU.",
        "rama_ia": "Búsqueda y optimización heurística",
        "tecnica": "Metaheurística de búsqueda local + telemática",
        "kpi_principal": "100 M millas y 10 M galones menos por año",
        "kpi_valor": "100 M",
        "kpi_etiqueta": "millas menos por año",
        "fuente": "Holland et al. (2017)",
        "anio": 2017,
    },
]


# ---------------------------------------------------------------------------
# 2. MATRIZ COMPARATIVA
# ---------------------------------------------------------------------------
def construir_matriz(casos):
    cols = ["caso", "rama_ia", "tecnica", "sector", "kpi_principal", "pais", "fuente", "anio"]
    return pd.DataFrame(casos)[cols]


# ---------------------------------------------------------------------------
# 3. MÉTRICAS DE VERIFICACIÓN (comprueban la coherencia de las cifras publicadas)
# ---------------------------------------------------------------------------
def ppv_npv(sens, spec, prevalencia):
```

```
    """Valores predictivos positivo/negativo (Bayes) para una prevalencia dada."""
    tp = sens * prevalencia
    fn = (1 - sens) * prevalencia
    tn = spec * (1 - prevalencia)
    fp = (1 - spec) * (1 - prevalencia)
    return tp / (tp + fp), tn / (tn + fn)


def millas_por_conductor_dia(millas_anuales, conductores, dias_laborales=250):
    """Ahorro diario por conductor. dias_laborales es SUPUESTO del alumno."""
    return millas_anuales / conductores / dias_laborales


def verificaciones():
    out = {}
    # IDx-DR: prevalencia 10 % es HIPOTÉTICA (ilustra el efecto de la prevalencia)
    ppv, npv = ppv_npv(0.872, 0.907, 0.10)
    out["IDx-DR PPV (prev. 10 %)"] = f"{ppv:.1%}"
    out["IDx-DR NPV (prev. 10 %)"] = f"{npv:.1%}"
    # ORION: 100 M millas / 55,000 conductores / 250 días
    out["ORION millas/conductor/día"] = f"{millas_por_conductor_dia(100e6, 55_000):.1f}"
    # Google: consistencia -40 % enfriamiento -> -15 % sobrecarga PUE (cifras publicadas)
    out["Google: ratio PUE/enfriamiento"] = f"{15 / 40:.3f}"
    return out


# ---------------------------------------------------------------------------
# 4. INFOGRAFÍA COMPARATIVA
# ---------------------------------------------------------------------------
def infografia(casos, ruta="infografia_comparativa.png"):
    """Infografía tipo ruta: cada caso es un carril con 5 etapas (problema -> datos -> técnica -> decisión ->
impacto)."""
    from matplotlib.patches import Polygon
    colores = ["#0F7B6C", "#C2570C", "#1F2A5C"]
    etapas = ["1  PROBLEMA", "2  DATOS", "3  TÉCNICA DE IA", "4  DECISIÓN", "5  IMPACTO MEDIBLE"]
    carriles = [
        ["Tamizaje de retinopatía diabética que depende de especialistas",
         "Imágenes de fondo de ojo (900 pacientes, 10 consultorios)",
         "Aprendizaje profundo y visión por computadora",
         "Referir o no al paciente con un especialista",
         "87.2 %|sensibilidad · 90.7 % especificidad"],
        ["El enfriamiento del centro de datos consume mucha energía",
         "Datos históricos de sensores de la instalación",
         "Redes neuronales (aprendizaje supervisado)",
         "Ajustar el enfriamiento según el PUE y la temperatura predichos",
         "-40 %|energía de enfriamiento"],
        ["Ruta diaria de cada uno de los 55,000 conductores",
         "Paquetes del día, datos telemáticos y de direcciones",
         "Metaheurística (búsqueda y optimización heurística)",
         "Ruta optimizada y consistente de un día a otro",
         "100 M|millas menos por año"],
    ]
    fig, ax = plt.subplots(figsize=(11, 6.8), dpi=200)
    ax.set_xlim(0, 100); ax.set_ylim(0, 100); ax.axis("off")
    ax.text(2, 96, "De la necesidad al impacto: la ruta de tres casos reales de IA", fontsize=14.5,
            fontweight="bold", color="#1F2A5C", va="center")
    ax.text(2, 91.6, "Salud · Industria · Movilidad", fontsize=9.5, color="#666666", va="center")
    x_ini, ancho, punta = 13.5, 16.9, 2.6
    for i, e in enumerate(etapas):                       # encabezados de etapa
        ax.text(x_ini + i * ancho + ancho / 2, 86.2, e, ha="center", va="center", fontsize=7.4,
                fontweight="bold", color="#444444")
    for j, (c, col, textos) in enumerate(zip(casos, colores, carriles)):
        y0 = 62 - j * 26; alto = 20
        ax.add_patch(plt.Rectangle((1.5, y0), 10.5, alto, fc=col, ec="none"))   # etiqueta del carril
        ax.text(6.75, y0 + alto * 0.68, c["sector"].split(" /")[0].upper(), ha="center", va="center",
                color="white", fontsize=8.6, fontweight="bold")
        ax.text(6.75, y0 + alto * 0.36, _envolver(c["caso"].split(" (")[0], 13), ha="center", va="center",
                color="white", fontsize=6.6)
        for i, t in enumerate(textos):
            x = x_ini + i * ancho
            pts = [(x, y0), (x + ancho - punta, y0), (x + ancho, y0 + alto / 2), (x + ancho - punta, y0 + alto),
(x, y0 + alto)]
            if i > 0:
                pts.append((x + punta, y0 + alto / 2))
            ultimo = i == len(textos) - 1
            ax.add_patch(Polygon(pts, closed=True, fc=col if ultimo else "#F4F5FA", ec=col, lw=1.4,
                                 alpha=1 if ultimo else 0.55 + 0.1 * i))
```

```
            cx, cy = x + ancho / 2 + (0.6 if i else -0.2), y0 + alto / 2
            if ultimo:
                num, lab = t.split("|")
                ax.text(cx, cy + 3.6, num, ha="center", va="center", color="white", fontsize=22, fontweight="bold")
                ax.text(cx, cy - 4.2, _envolver(lab, 17), ha="center", va="center", color="white", fontsize=6.8)
            else:
                ax.text(cx, cy, _envolver(t, 20), ha="center", va="center", color="#222222", fontsize=6.8)
    ax.text(2, 3.0, "Fuentes: Abràmoff et al. (2018) · Evans y Gao (2016) · Holland et al. (2017)", fontsize=7,
            color="#666666", va="center")
    ax.text(98, 3.0, "Elaboración propia", fontsize=7, color="#666666", va="center", ha="right")
    fig.savefig(ruta, bbox_inches="tight"); plt.close(fig)
    return ruta


def _envolver(texto, n):
    palabras, linea, lineas = texto.split(), "", []
    for p in palabras:
        if len(linea) + len(p) + 1 > n:
            lineas.append(linea)
            linea = p
        else:
            linea = (linea + " " + p).strip()
    lineas.append(linea)
    return "\n".join(lineas)


# ---------------------------------------------------------------------------
# 5. EJECUCIÓN
# ---------------------------------------------------------------------------
if __name__ == "__main__":
    matriz = construir_matriz(CASOS)
    matriz.to_csv("matriz_casos_ia.csv", index=False, encoding="utf-8-sig")
    print(matriz.to_string(index=False))
    print("\n--- Verificaciones ---")
    for k, v in verificaciones().items():
        print(f"{k}: {v}")
    print("\nInfografía:", infografia(CASOS))
```

Capítulo 8. Análisis y discusión

8.1 Tipo de problema y técnica

Los tres casos usan IA de forma distinta: IDx-DR **clasifica** imágenes (aprendizaje profundo), el caso de Google **predice** el comportamiento de un sistema físico para decidir cuánto enfriar (aprendizaje supervisado) y ORION **busca** la mejor secuencia de paradas en un espacio combinatorio (búsqueda heurística). ORION se relaciona directamente con los temas siguientes del curso: ascenso de colina y recocido simulado (sección 3), y búsqueda con heurísticas como A* y Dijkstra (sección 5).

8.2 Calidad de la evidencia

Caso	Evidencia	Fortaleza	Riesgo
IDx-DR	Ensayo prospectivo, 900 personas, metas pre-especificadas	Alta: método descrito y revisión por pares	Generalización limitada por cámara y criterios de exclusión
Google / DeepMind	Prueba en un centro de datos en operación	Media: resultado claro, pero sin revisión por pares en la fuente	Cifras autorreportadas; “hasta 40 %”
UPS ORION	Despliegue a escala nacional, premio Edelman	Alta: artículo revisado por pares y años de operación	Ahorros estimados por la empresa

8.3 Aspectos éticos y técnicos

- **Salud:** un sistema autónomo desplaza la interpretación del médico; un falso negativo retrasa la atención, por lo que la sensibilidad es un criterio de seguridad del paciente (Abràmoff et al., 2018) y la responsabilidad debe estar claramente asignada.
- **Industria:** medir el ahorro exige una línea base y una metodología transparente; sin revisión independiente, el resultado debe leerse como evidencia preliminar.
- **Movilidad:** optimizar rutas con datos telemáticos plantea preguntas de privacidad y aceptación de los conductores; el equipo de UPS incorporó la consistencia de rutas precisamente para lograr esa aceptación (Holland et al., 2017).
- **Común a los tres:** el impacto depende de integrar el modelo en un proceso real (consultorio, sala de control, operación de reparto), no solo del algoritmo.

Capítulo 9. Conclusiones reflexivas

- Los tres casos cumplen el patrón datos del dominio + modelo de IA + decisión con KPI verificable; la IA genera valor cuando el problema está bien definido y se mide.
- No existe una “IA única”: la rama adecuada depende del problema (clasificar, predecir u optimizar), lo que justifica estudiar aprendizaje automático y búsqueda en este curso.
- La solidez de la evidencia difiere: el ensayo clínico y el artículo en *Interfaces* sustentan mejor sus cifras que un blog corporativo; conviene citar siempre la fuente primaria y distinguir lo reportado de lo verificado.
- Los resultados son prometedores, pero tienen límites de generalización, costo y responsabilidad; evaluar una aplicación de IA implica considerar también riesgos éticos y de implementación.
- Este tipo de análisis sirve como criterio para evaluar proyectos propios del portafolio: definir el problema, elegir la técnica, medir con un KPI y documentar la fuente.

Capítulo 10. Plus: Escala de Evidencia de IA (EEIA) y fuentes verificables

Un KPI es útil solo si se sabe cuánto confiar en él. Para distinguir **lo reportado** de **lo bien documentado**, se diseñó una rúbrica propia de cinco criterios, cada uno con 0, 1 o 2 puntos (máximo 10). La EEIA **no mide si la IA funciona**, sino qué tan sólida es la evidencia públicamente disponible sobre el caso.

10.1 Rúbrica

Criterio	2 puntos	1 punto	0 puntos
C1 Revisión editorial	Artículo revisado por pares	Memoria o informe institucional con autoría	Blog o comunicado corporativo
C2 Método descrito	Diseño, datos y métricas descritos	Descripción general	Sin descripción
C3 KPI cuantificado	Con intervalo, meta o línea base explícita	Cifra sin incertidumbre ni línea base	Solo cualitativo
C4 Evaluación independiente	Evaluador externo a quien desarrolla	Parcial (referencia o jurado externos)	Autorreportado
C5 Replicabilidad	Datos o código abiertos	Protocolo descrito, sistema propietario	No reproducible

10.2 Puntajes y justificación

Caso	C1	C2	C3	C4	C5	Total	Justificación
IDx-DR	2	2	2	1	1	**8/10**	Revista revisada por pares; ensayo prospectivo con metas e intervalos de confianza; referencia en un centro de lectura independiente, pero el ensayo evalúa un sistema propietario (revisar la declaración de conflictos de interés del artículo).
Google / DeepMind	0	1	1	0	0	**2/10**	Publicación técnica de la propia empresa; descripción general del método; cifras de ahorro sin intervalos; no hay evaluación externa ni datos abiertos.
UPS ORION	2	1	1	1	0	**5/10**	Artículo en revista revisada por pares y proyecto finalista de un premio con jurado externo; cifras agregadas sin línea base detallada; algoritmo y datos propietarios.



Figura 2. Radar de la EEIA por caso. Elaboración propia con Python (script `fia_s1_plus_eeia.py`).

10.3 Interpretación

- El caso con mejor evidencia (IDx-DR) es también el único con ensayo clínico prospectivo y metas definidas de antemano; ese diseño explica su puntaje alto.
- Un puntaje bajo no significa que el resultado sea falso: indica que, con lo publicado, **no puede comprobarse de forma independiente**, por lo que conviene citarlo como “reportado por la empresa”.
- La rúbrica es **subjetiva** (criterio del autor) y se justifica puntaje por puntaje para que cualquiera pueda discutirla o recalcularla con el script.
- Esta escala puede reutilizarse en los proyectos del portafolio para decidir con cuánta confianza apoyarse en una fuente.

10.4 Tarjetas de fuentes (escanear el código QR para abrir la fuente primaria)

IDx-DR
Abràmoff et al. (2018)
EEIA 8/10
https://doi.org/10.1038/s41746-018-0040-6

Google / DeepMind
Evans y Gao (2016)
EEIA 2/10
https://deepmind.google/discover/blog/deepmind-ai-reduces-google-data-centre-cooling-bill-by-40/

UPS ORION
Holland et al. (2017)
EEIA 5/10
https://doi.org/10.1287/inte.2016.0875

10.5 Código del plus

```
"""
PLUS Sección 1: Escala de Evidencia de IA (EEIA), rúbrica propia de 5 criterios (0-2 pts c/u, máx. 10).
Evalúa qué tan sólida es la evidencia publicada de cada caso. Es un criterio SUBJETIVO del alumno,
con justificación por cada puntaje. Genera: eeia_radar.png y eeia_puntajes.csv
Requisitos: pip install matplotlib pandas
"""
import numpy as np
import pandas as pd
import matplotlib
matplotlib.use("Agg")
import matplotlib.pyplot as plt

CRITERIOS = ["Revisión editorial", "Método descrito", "KPI cuantificado", "Evaluación independiente",
"Replicabilidad"]
# 0 = no cumple · 1 = cumple parcialmente · 2 = cumple
PUNTAJES = {
    "IDx-DR (salud)":        [2, 2, 2, 1, 1],
    "Google/DeepMind (industria)": [0, 1, 1, 0, 0],
    "UPS ORION (movilidad)": [2, 1, 1, 1, 0],
}
COLORES = ["#0F7B6C", "#C2570C", "#1F2A5C"]


def tabla():
    df = pd.DataFrame(PUNTAJES, index=CRITERIOS).T
    df["Total /10"] = df.sum(axis=1)
    return df


def radar(ruta="eeia_radar.png"):
    ang = np.linspace(0, 2 * np.pi, len(CRITERIOS), endpoint=False).tolist()
    ang += ang[:1]
    fig, ax = plt.subplots(figsize=(6.4, 6.4), dpi=200, subplot_kw=dict(polar=True))
    for (caso, v), col in zip(PUNTAJES.items(), COLORES):
        vals = v + v[:1]
        ax.plot(ang, vals, color=col, lw=2, label=f"{caso}: {sum(v)}/10")
        ax.fill(ang, vals, color=col, alpha=0.12)
    ax.set_xticks(ang[:-1]); ax.set_xticklabels([c.replace(" ", "\n", 1) for c in CRITERIOS], fontsize=8)
    ax.set_yticks([0, 1, 2]); ax.set_ylim(0, 2); ax.set_yticklabels(["0", "1", "2"], fontsize=7)
    ax.set_title("Escala de Evidencia de IA (EEIA)", fontsize=12, fontweight="bold", pad=18)
    ax.legend(loc="upper center", bbox_to_anchor=(0.5, -0.08), fontsize=8, frameon=False)
    fig.savefig(ruta, bbox_inches="tight"); plt.close(fig)


if __name__ == "__main__":
    df = tabla()
    print(df.to_string())
    df.to_csv("eeia_puntajes.csv", encoding="utf-8-sig")
    radar()
    print("Generado: eeia_radar.png, eeia_puntajes.csv")
```

Salida real de la ejecución:

```
Revisión editorial  Método descrito  KPI cuantificado  Evaluación independiente  Replicabilidad  Total /10
IDx-DR (salud)                                2                2                 2                          1
1          8
Google/DeepMind (industria)                   0                1                 1                          0
0          2
UPS ORION (movilidad)                         2                1                 1                          1
0          5
Generado: eeia_radar.png, eeia_puntajes.csv
```

Capítulo 11. Referencias (APA 7.ª ed.)

Abràmoff, M. D., Lavin, P. T., Birch, M., Shah, N., & Folk, J. C. (2018). Pivotal trial of an autonomous AI-based diagnostic system for detection of diabetic retinopathy in primary care offices. *npj Digital Medicine, 1*, Artículo 39. https://doi.org/10.1038/s41746-018-0040-6

Evans, R., & Gao, J. (2016, 20 de julio). *DeepMind AI reduces Google data centre cooling bill by 40%*. Google DeepMind. https://deepmind.google/discover/blog/deepmind-ai-reduces-google-data-centre-cooling-bill-by-40/

García Serrano, A. (2016). *Inteligencia artificial: Fundamentos, práctica y aplicaciones* (2.ª ed.). RC Libros.

Holland, C., Levis, J., Nuggehalli, R., Santilli, B., & Winters, J. (2017). UPS optimizes delivery routes. *Interfaces, 47*(1), 8–23. https://doi.org/10.1287/inte.2016.0875

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56–61. https://doi.org/10.25080/Majora-92bf1922-00a

"ORION" delivers success for UPS. (2016, 6 de junio). *ORMS Today*. https://doi.org/10.1287/orms.2016.03.10

Russell, S., & Norvig, P. (2020). *Inteligencia artificial: Un enfoque moderno* (4.ª ed.). Pearson.

With an eye to AI and autonomous diagnosis. (2018). *npj Digital Medicine, 1*, Artículo 40. https://doi.org/10.1038/s41746-018-0048-y

Anexo A. Lista de cotejo (sección 1)

#	Criterio de evaluación	S1
1	Portada, tema, sección y datos del problema completos en el PDF	✓
2	Planteamiento, formulación y procedimiento claramente explicados	✓
3	Código Python funcional y comentado, probado con datos de entrada	✓
4	Solución enmarcada, con gráficos, tablas o diagramas de resultados	✓
5	Repositorio GitHub con carpeta del alumno, README y PDFs	✓
6	Declaración de IA utilizada, referencias APA 7 y conclusiones reflexivas	✓

Declaración de uso de IA

Herramienta: Claude (Anthropic), asistente conversacional con búsqueda web.
Prompt: Analiza el documento y dale formato de acuerdo a la imagen siguiente, verifica que cumpla cada criterio y revisa faltas ortográficas y modifica según sea el caso, localiza fuentes para verificar acerca de la actividad y genera el código python necesario.
Uso: apoyo para localizar fuentes, estructurar y redactar el borrador del reporte y generar el script de Python, la rúbrica EEIA y el diseño del documento.
Verificación: las cifras de cada caso se contrastaron con la fuente primaria (artículo, publicación oficial o revista) y el código se ejecutó y su salida se incluyó en el capítulo 6. Revisión personal de enlaces y cifras por el alumno: [fecha].